1. Data Mining a analityka gospodarcza

Data Mining można rozumieć jako systematyczne odkrywanie użytecznych wzorców w danych. Słowo "użytecznych" jest kluczowe: wzorzec ma znaczenie wtedy, gdy pomaga lepiej opisać sytuację, przewidzieć zdarzenie albo podjąć decyzję. Samo znalezienie statystycznej zależności nie wystarcza. Organizacja musi wiedzieć, co z tą zależnością zrobić, jaki jest koszt działania i jaki jest koszt błędu.

W analityce gospodarczej punkt wyjścia stanowi problem organizacji. Przykładowo firma może chcieć ograniczyć odejścia klientów, poprawić skuteczność kampanii, lepiej zaplanować zapasy lub wykrywać nietypowe transakcje. Dopiero potem wybiera się sposób analizy. Ta kolejność chroni przed sytuacją, w której zespół buduje interesujący technicznie model, który nie odpowiada na żadną realną potrzebę.

Data Mining łączy elementy statystyki, uczenia maszynowego, baz danych, wizualizacji i wiedzy domenowej. Nie jest jednak tożsamy z żadnym z tych obszarów. Statystyka pomaga wnioskować i oceniać niepewność, uczenie maszynowe dostarcza algorytmów, bazy danych umożliwiają dostęp i integrację, a wiedza domenowa pozwala stwierdzić, czy wynik ma sens gospodarczy.

Obszar	Główne pytanie	Typowy rezultat
Business Intelligence	Co wydarzyło się w organizacji?	Raport, dashboard, KPI
Statystyka	Jakie zależności występują i jak pewne są wnioski?	Estymacja, test, przedział ufności
Machine Learning	Jak zbudować regułę przewidywania lub grupowania?	Model i predykcja
Data Mining	Jak przejść od problemu i danych do użytecznego wzorca i decyzji?	Kompletny proces analityczny

Przykład

Wysoka dokładność modelu churn nie jest jeszcze sukcesem. Sukcesem jest sytuacja, w której model pozwala wybrać grupę klientów do działania, działanie jest opłacalne, a wynik można monitorować.

2. Od problemu biznesowego do zadania analitycznego

Dobre pytanie biznesowe wskazuje decyzję, odbiorcę i horyzont czasowy. Pytanie "co można zrobić z tym zbiorem?" jest zbyt szerokie. Pytanie "których klientów skierować do kampanii retencyjnej w przyszłym miesiącu, aby ograniczyć utratę marży?" jest znacznie lepsze, ponieważ określa obiekt, działanie i cel ekonomiczny.

Pytanie techniczne powinno wynikać z pytania biznesowego. Jeżeli organizacja chce przewidywać odejście klienta, powstaje zadanie klasyfikacji. Jeżeli chce opisać typy klientów bez gotowej etykiety, powstaje zadanie klasteryzacji. Jeżeli chce odnaleźć produkty występujące razem, używa reguł asocjacyjnych. Jeżeli chce oszacować przyszłą sprzedaż, analizuje szereg czasowy.

Kryterium sukcesu musi obejmować co najmniej dwa poziomy. Poziom analityczny opisuje jakość wyniku, na przykład recall, błąd prognozy albo silhouette score. Poziom biznesowy opisuje efekt decyzji, na przykład dodatkową marżę, ograniczenie kosztu, wzrost konwersji albo skrócenie czasu kontroli.

Problem gospodarczy	Zadanie analityczne	Przykładowa decyzja
Ryzyko odejścia klientów	Klasyfikacja	Wybór klientów do kampanii
Produkty kupowane razem	Reguły asocjacyjne	Rekomendacja, pakiet, ekspozycja
Niejednorodna baza klientów	Klasteryzacja	Zróżnicowanie komunikacji
Nietypowe transakcje	Detekcja anomalii	Kolejka do weryfikacji
Planowanie sprzedaży	Szereg czasowy	Obsada, zapasy, budżet

3. CRISP-DM - proces prowadzenia projektu

CRISP-DM porządkuje projekt w sześciu etapach: Business Understanding, Data Understanding, Data Preparation, Modeling, Evaluation oraz Deployment. Model nie jest początkiem procesu ani jego końcem. Jest jednym z etapów pomiędzy zrozumieniem problemu a wykorzystaniem wyniku.

Proces jest iteracyjny. Podczas przygotowania danych można odkryć, że zmienna celu została źle zdefiniowana. Podczas oceny modelu może okazać się, że metryka nie odpowiada kosztom błędów. Po wdrożeniu może pojawić się drift danych, który wymaga powrotu do wcześniejszych etapów. Cofnięcie się w procesie nie jest porażką; jest elementem kontroli jakości.

Etap CRISP-DM	Najważniejsze pytania	Oczekiwany rezultat
Business Understanding	Jaka decyzja ma zostać podjęta? Jak mierzymy sukces?	Karta problemu i kryteria sukcesu
Data Understanding	Co oznacza jeden wiersz? Jakie są typy, braki i rozkłady?	Opis danych i wstępna diagnoza
Data Preparation	Jak oczyścić, połączyć i przekształcić dane?	Reprodukowalny zbiór analityczny
Modeling	Jaka metoda odpowiada zadaniu i jakie są warianty?	Modele oraz ustawienia
Evaluation	Czy wynik jest poprawny technicznie i użyteczny gospodarczo?	Ocena, ograniczenia, rekomendacja
Deployment	Jak wynik trafi do procesu i jak będzie monitorowany?	Raport, dashboard, procedura lub system

Ważne rozróżnienie

Evaluation nie oznacza tylko sprawdzenia metryki. Obejmuje również pytanie, czy model odpowiada na pierwotny problem, czy korzysta z danych dostępnych w momencie decyzji oraz czy jego użycie jest legalne i proporcjonalne.

4. Rozumienie danych i EDA

Eksploracyjna analiza danych (EDA) ma pomóc zrozumieć strukturę zbioru przed modelowaniem. Obejmuje kontrolę liczby rekordów, typów danych, braków, duplikatów, rozkładów, wartości odstających i zależności między zmiennymi. EDA nie jest etapem produkowania możliwie wielu wykresów. Każdy wykres powinien odpowiadać na pytanie o jakość, strukturę lub potencjalny wzorzec.

Jednostka obserwacji określa, co reprezentuje jeden wiersz. Może to być klient, transakcja, produkt, sklep w danym dniu lub pojedyncze zdarzenie. Jeżeli jednostka nie jest jasno określona, łatwo policzyć błędne agregaty, podwójnie uwzględnić ten sam obiekt albo połączyć tabele o niezgodnej ziarnistości.

Zmienne mogą być liczbowe, kategoryczne nominalne, porządkowe, binarne, czasowe, tekstowe lub identyfikacyjne. Typ techniczny w pliku nie zawsze odpowiada znaczeniu. Kod pocztowy zapisany jako liczba pozostaje kategorią, a ocena 1-5 ma porządek, ale odległości między kolejnymi wartościami nie muszą mieć identycznego znaczenia.

Pytanie EDA	Przykładowa kontrola	Ryzyko przy pominięciu
Co oznacza rekord?	Jednostka obserwacji i klucz	Podwójne liczenie
Czy dane są kompletne?	Liczba i wzorzec braków	Systematyczne zniekształcenie
Czy wartości są możliwe?	Zakresy i reguły biznesowe	Model uczy się błędów
Czy klasy są zbalansowane?	Udział zmiennej celu	Myląca accuracy
Czy cecha nie ujawnia wyniku?	Dostępność w momencie decyzji	Data leakage

5. Jakość danych, zmienna celu i data leakage

Jakość danych jest wielowymiarowa. Obejmuje poprawność, kompletność, spójność, aktualność, unikalność oraz zgodność z przeznaczeniem. Zbiór może być technicznie poprawny, lecz nieprzydatny do konkretnej decyzji, na przykład gdy dane są dostępne zbyt późno albo nie obejmują grupy klientów, której ma dotyczyć model.

Zmienna celu opisuje wynik, który chcemy przewidywać. Musi mieć jasną definicję, horyzont i moment pomiaru. "Klient odszedł" może oznaczać wypowiedzenie umowy, brak aktywności przez 90 dni albo brak kolejnego zakupu. Różne definicje prowadzą do różnych modeli i różnych decyzji.

Data leakage występuje, gdy model korzysta z informacji niedostępnej w momencie rzeczywistej predykcji albo z informacji pośrednio zawierającej odpowiedź. Model może wtedy osiągać znakomite wyniki testowe, które znikają po wdrożeniu. Typowym przykładem jest użycie daty zamknięcia konta do przewidywania odejścia klienta.

Test anty-leakage

Dla każdej cechy zapytaj: czy ta informacja była znana dokładnie w chwili, w której organizacja miałaby podjąć decyzję? Jeżeli odpowiedź brzmi "nie", cecha nie powinna trafiać do modelu.

6. Mapa metod Data Mining

Podstawowe rozróżnienie dotyczy uczenia nadzorowanego i nienadzorowanego. W uczeniu nadzorowanym istnieje znany wynik dla danych historycznych, na przykład odejście klienta. Model uczy się zależności między cechami a wynikiem. W uczeniu nienadzorowanym nie ma gotowej etykiety; celem jest odkrycie struktury, na przykład segmentów albo obserwacji nietypowych.

Wybór metody powinien wynikać z rodzaju pytania i danych. Nie należy stosować klasyfikacji, jeżeli organizacja nie posiada wiarygodnej zmiennej celu. Nie należy nazywać klastrów "dobrymi" tylko dlatego, że algorytm zwrócił cztery grupy. Wynik metody jest początkiem interpretacji, a nie końcem analizy.

Metoda	Czy ma zmienną celu?	Wynik	Przykład
Klasyfikacja	Tak	Klasa lub prawdopodobieństwo	Odejście klienta
Reguły asocjacyjne	Nie	Reguły X -> Y	Produkty w koszyku
Klasteryzacja	Nie	Grupy podobnych obserwacji	Segmenty klientów
Detekcja anomalii	Zwykle nie	Score nietypowości	Podejrzane transakcje
Szeregi czasowe	Wartość w przyszłości	Prognoza i niepewność	Sprzedaż dzienna

7. Ocena, wdrożenie i komunikacja

Wynik analizy powinien być przedstawiony językiem decyzji. Odbiorca potrzebuje informacji: co model przewiduje, jak dobry jest wynik, jakie błędy popełnia, kogo lub czego dotyczy, kiedy nie należy mu ufać oraz jakie działanie proponujemy. Sam wykres ROC albo tabela z parametrami modelu nie odpowiada na te pytania.

Wdrożenie może oznaczać integrację modelu z systemem, ale może też oznaczać cykliczny raport, scoring w arkuszu, procedurę kontroli lub rekomendację jednorazową. Każda forma wymaga określenia właściciela procesu, częstotliwości aktualizacji i sposobu monitorowania.

Po wdrożeniu trzeba monitorować jakość danych, zmianę rozkładów, skuteczność decyzji i skutki uboczne. Model z czasem może tracić jakość, ponieważ zmieniają się zachowania klientów, oferta firmy, otoczenie gospodarcze albo sposób rejestrowania danych.

8. Etyka i odpowiedzialność analityka

Odpowiedzialna analiza obejmuje prywatność, minimalizację danych, proporcjonalność celu, bezpieczeństwo, sprawiedliwość i możliwość wyjaśnienia decyzji. Zgoda marketingowa nie oznacza automatycznie zgody na dowolne profilowanie, a techniczna dostępność danych nie jest równoznaczna z prawem do ich użycia.

Bias może pojawić się w sposobie zbierania danych, definicji celu, historycznych decyzjach, próbie uczącej lub doborze metryki. Model może odtwarzać wcześniejsze nierówności nawet wtedy, gdy usuniemy bezpośrednio wrażliwą zmienną, ponieważ inne cechy mogą działać jako proxy.

Analityk odpowiada nie tylko za kod, lecz także za komunikowanie ograniczeń. Powinien unikać fałszywej precyzji, nie sugerować przyczynowości bez podstaw i nie ukrywać kosztów błędów. Automatyczna decyzja powinna mieć zakres adekwatny do ryzyka; w sprawach o dużych konsekwencjach potrzebna jest kontrola człowieka.

9. Przykład przekrojowy: NovaTel

NovaTel chce ograniczyć odejścia klientów. Business Understanding obejmuje ustalenie, że decyzją jest skierowanie części klientów do kampanii retencyjnej, a sukcesem nie jest sama dokładność modelu, lecz ograniczenie utraconej marży przy kontrolowanym koszcie kontaktu.

Data Understanding wymaga ustalenia, że jeden wiersz oznacza klienta w dniu migawki, zmienna celu opisuje odejście w ciągu 90 dni, a dane pochodzą z systemu umów, płatności, obsługi i aktywności. Trzeba sprawdzić braki, duplikaty, rozkład klas i moment dostępności cech.

Data Preparation obejmuje ujednolicenie kategorii, obsługę braków, konstrukcję cech i wyłączenie informacji ujawniającej wynik. Modeling może obejmować regresję logistyczną, drzewo i Random Forest. Evaluation musi uwzględniać koszt pominięcia klienta oraz koszt zbędnej oferty. Deployment powinien prowadzić do testu kampanii, nie do bezrefleksyjnego automatycznego rabatu.

Etap	Pytanie kontrolne w NovaTel
Business	Czy kampania ma zatrzymać klientów, czy jedynie przewidywać odejście?
Data	Czy cechy są dostępne przed decyzją?
Preparation	Jak obsłużyć brak dochodu i niespójne kanały?
Modeling	Który model daje użyteczny ranking ryzyka?
Evaluation	Jaki jest koszt FN i FP?
Deployment	Jak sprawdzić, czy interwencja rzeczywiście działa?

Słownik najważniejszych pojęć

Pojęcie	Znaczenie
Data Mining	Proces odkrywania i wykorzystania użytecznych wzorców w danych.
CRISP-DM	Iteracyjny model prowadzenia projektu Data Mining.
Jednostka obserwacji	Obiekt lub zdarzenie reprezentowane przez jeden wiersz.
Zmienna celu	Wynik, który model ma przewidywać.
EDA	Eksploracyjna analiza struktury i jakości danych.
Data leakage	Wykorzystanie informacji niedostępnej w momencie decyzji.
Deployment	Włączenie wyniku analizy do procesu organizacji.
Bias	Systematyczne zniekształcenie danych, modelu lub decyzji.